

Asociación

Aprendizaje Maquinal

René Mac Kinney Romero


UAM - Iztapalapa

- Tipos de aprendizaje
- Tareas de aprendizaje
- *Apriori*
- Ejemplo *Apriori*


Tipos aprendizaje maquina

Dependiendo de lo que se desea hacer con los datos, descubrimiento o predicción de información.


El aprendizaje se puede clasificar en: *supervisado* y *no supervisado*.




Datos etiquetados



Datos no etiquetados



Aprendizaje supervisado




Aprendizaje no supervisado


Tareas de Aprendizaje Maquinal

Son cuatro las tareas más comunes:

- **Clasificación** (C4.5, adaboost, vecinos más cercanos, bayes ingenuo)




- **Regresión** (mínimos cuadrados, cart)




Tareas de Aprendizaje Maquinal ...

- **Agrupamiento** (*K*-means, esperanza-maximización)



- **Reglas de asociación** (*apriori*)



Apriori (RAE)

Loc. lat.; literalmente 'de lo anterior'.

- ① loc. adv. Antes de examinar el asunto de que se trata. U. t. c. loc. adj.
- ② loc. adv. Fil. Descendiendo de la causa al efecto o de la esencia de una cosa a sus propiedades. Demostrar a priori. U. t. c. loc. adj.
Razonamiento a priori.

Algoritmo *Apriori*

Data: Conjunto de datos a asociar

$L_1 = \{ \text{conjuntos candidatos de tamaño } 1 \}$

Result: L_k

for $k = 2$ **to** $L_k \neq 0$ **do**

$C_k = \text{apriori-gen}(L_{k-1});$ //Generar nuevos candidatos **forall**

transacciones $t \in D$ **do**

$C_t = \text{subconjunto}(C_k, t);$ //Candidatos contenidos en t **forall**

candidatos $c \in C_t$ **do**

$c.\text{contador}++;$

end

end

$L_k = \{c \in C_k | c.\text{contador} \geq \text{soporte minimo}\}$

end

Algoritmo 1: *Apriori*

Ejemplo

Lista de transacciones

Transaction No	Products
1	beer, wine, cheese
2	beer, potato chips
3	eggs, flour, butter, cheese
4	eggs, flour, butter, beer, potato chips
5	wine, cheese
6	potato chips
7	eggs, flour, butter, wine, cheese
8	eggs, flour, butter, beer, potato chips
9	wine, beer
10	beer, potato chips
11	butter, eggs
12	beer, potato chips
13	flour, eggs
14	beer, potato chips
15	eggs, flour, butter, wine, cheese
16	beer, wine, potato chips, cheese
17	wine, cheese
18	beer, potato chips
19	wine, cheese
20	beer, potato chips

El algoritmo se basa en la noción de **soporte**.

El soporte es simplemente el número de transacciones en las que se produce un producto específico (o combinación de productos).

Productos con soporte

El primer paso del algoritmo es calcular el soporte de cada elemento individual. Básicamente, esto se reduce a contar, para cada producto, en cuántas transacciones aparece.

Product	Number of occurrences
Wine	8
Cheese	8
Beer	11
Potato Chips	10
Eggs	7
Flour	6
Butter	6

Ahora que tenemos el soporte para cada uno de los productos individuales, lo usaremos para filtrar algunos de los productos que no son frecuentes. Para hacerlo, debemos decidir un umbral de soporte. Para nuestro ejemplo actual, usemos 7 como mínimo.

Selección de los artículos frecuentes

Es fácil ver que hay dos productos individuales que tienen un soporte de menos de 7 (lo que significa que tienen menos de 7 ocurrencias). Esos productos son Harina y Mantequilla.

Desafortunadamente para Harina y Mantequilla, no se considerarán en pasos posteriores.

Encontrar el soporte de los conjuntos de elementos frecuentes

El próximo paso es hacer el mismo análisis, pero ahora utilizando pares de productos en lugar de productos individuales. Como puede imaginar, la cantidad de combinaciones puede aumentar rápidamente aquí, especialmente si tiene una gran cantidad de productos.

El gran 'invento' detrás del algoritmo Apriori es que directamente ignoraremos todos los pares que contengan alguno de los elementos no frecuentes. Gracias a esto, tenemos muchos menos pares de elementos para tomar en cuenta.

Encontrar el soporte de los conjuntos de elementos frecuentes ...

Aquí hay una lista de todos los pares que contienen mantequilla, harina o ambos. Todos esos pueden descartarse y esto acelerará la ejecución de nuestros conteos.

Itemset	Number of occurrences
Flour, Wine	IGNORE: no need to count
Flour, Cheese	IGNORE: no need to count
Flour, Potato Chips	IGNORE: no need to count
Flour, Eggs	IGNORE: no need to count
Flour, Butter	IGNORE: no need to count
Butter, Wine	IGNORE: no need to count
Butter, Cheese	IGNORE: no need to count
Butter, Beer	IGNORE: no need to count
Butter, Potato Chips	IGNORE: no need to count
Butter, Eggs	IGNORE: no need to count

Encontrar el soporte de los conjuntos de elementos frecuentes ...

Por supuesto, todavía hay algunas combinaciones que deben contarse en este ejemplo:

Itemset	Number of occurrences
Wine, Cheese	7
Wine, Beer	2
Wine, Potato Chips	1
Wine, Eggs	2
Cheese, Beer	2
Cheese, Potato Chips	1
Cheese, Eggs	3
Beer, Potato Chips	9
Beer, Eggs	2
Potato Chips, Eggs	2

Como puede ver, en este punto solo quedan dos combinaciones de productos que están por encima del soporte: *Vino y Queso*, y *Cerveza y Papas Fritas*.

Repita para conjuntos más grandes

Ahora repetiremos lo mismo para los conjuntos con tres productos. Como antes, no anotaremos conjuntos que fueron eliminados en el paso anterior. Los pares que quedaron fueron:

- Vino, Queso
- Cerveza, Patatas Fritas

Entonces, ¿qué tripletas podemos hacer que no contengan ninguna pareja que haya sido eliminada?

- Vino, Queso, Cerveza → eliminado por la presencia de un par no frecuente (por ejemplo Queso, Cerveza)
- Vino, Queso, Patatas Fritas → eliminado por la presencia de un par no frecuente (por ejemplo Queso, Patatas Fritas)
- Cerveza, papas fritas, vino → eliminado por la presencia de un par no frecuente (por ejemplo, vino, papas fritas)
- Queso, Cerveza, Patatas Fritas → eliminado por la presencia de un par no frecuente (por ejemplo Queso, Cerveza)

No hay trillizos que no contengan alguna pareja no frecuente.

Esto quiere decir que se han identificado los conjuntos frecuentes y son los

Genere reglas de asociación y calcule la confianza

Ahora que tiene los conjuntos de elementos frecuentes más grandes, el siguiente paso es convertirlos en reglas de asociación. Las Reglas de asociación van un paso más allá de simplemente listar productos que ocurren juntos con frecuencia.

Las reglas de asociación están escritas en el formato: Producto $X \Rightarrow$ Producto Y . Esto significa que obtiene una regla que le dice que si compra el producto X , es probable que también compre el producto Y .

Hay una medida adicional llamada confianza. La confianza le indica un porcentaje de casos en los que esta regla es válida. 100 % de confianza significa que esta asociación siempre ocurre; 50 %, por ejemplo, significa que la regla solo se mantiene el 50 % del tiempo.

Una vez que haya obtenido las reglas, el último paso es calcular el *lift* de cada regla. Según la definición, el aumento de una regla es una métrica de rendimiento que indica la fuerza de la asociación entre los productos de la regla.

La fórmula del levantamiento de una regla se muestra aquí:

$$lift = \frac{P(X \cup Y)}{P(X) * P(Y)}$$

Esto significa que la elevación (*lift*) básicamente compara la mejora de una regla de asociación con el conjunto de datos general. Si “cualquier producto $\Rightarrow X$ ” en el 10 % de los casos mientras que “ $A \Rightarrow X$ ” en el 75 % de los casos, la mejora sería del $75 \% / 10 \% = 7,5$.

Si la elevación de una regla es 1, entonces los productos son independientes entre sí. Cualquier regla que tenga un ascensor de 1 se puede descartar.

Si la elevación de una regla es superior a 1, el valor de la elevación le indica en qué medida el producto del lado derecho depende del lado izquierdo.

Precisión *Apriori*: ¿cómo equilibrar el apoyo, la confianza y el levantamiento de una regla?

Esto básicamente nos da tres métricas para interpretar:

- soporte (el número de veces, o porcentaje, que los productos ocurren simultáneamente)
- confianza (el número de veces que ocurre una regla, también la probabilidad condicional del lado derecho dado el lado izquierdo)
- *lift* (la fuerza de la asociación)

Esas tres métricas tienen su propia validez. Por lo tanto, es difícil elegir entre ellos. Por ejemplo, si tiene una regla que tiene un elevación más alta pero una confianza más baja que otra regla, sería difícil afirmar que una regla es “mejor que otra”. En este punto, es posible que desee mantener ambas reglas o tratar de encontrar una razón para preferir una métrica sobre la otra en su caso de uso específico.