

Técnicas de agrupamiento *Clustering*

René Mac Kinney Romero

UAM - Iztapalapa



Casa abierta al tiempo

- Aprendizaje no supervisado
- Categorías de agrupamiento
- Algoritmos de agrupamiento
 - ▶ K-means
 - ▶ Fuzzy c-means



Casa abierta al tiempo

- Definición 1

- ▶ Supervisado: esfuerzo humano involucrado
- ▶ No supervisado: sin esfuerzo humano

- Definición 2

- ▶ Supervisado: distribución condicional de aprendizaje $P(Y|X)$, X : características, Y : clases
- ▶ No supervisado: distribución de aprendizaje $P(X)$, X



Casa abierta al tiempo

¿Qué es la agrupación?



Casa abierta al tiempo

Definición

- Asignación de un conjunto de observaciones en subconjuntos para que las observaciones en el mismo subconjunto sean similares en algún sentido
- Métodos para manejar incertidumbre



La similaridad es difícil de definir pero.. "Sabemos cuando la vemos"
El verdadero significado es filosófico.

Nosotros necesitamos algo práctico.



Casa abierta al tiempo

- Duro vs. Blando
- Duro: el mismo objeto solo puede pertenecer a un solo clúster
- Blando: el mismo objeto puede pertenecer a diferentes clústeres
 - ▶ Por ejemplo: Modelo de mezcla gaussiana



Casa abierta al tiempo

- Plano vs Jerárquico

- ▶ Plano: los grupos son planos
- ▶ Jerárquico: los grupos forman un árbol
 - ★ Aglomerativo
 - ★ Divisivo




Casa abierta al tiempo

- Aglomerativo (de abajo hacia arriba)
 - ▶ Calcular todos los coeficientes de similitud de patrón por pares
 - ▶ Colocar cada uno de los n patrones en una clase propia
 - ▶ Combinar los dos grupos más similares en uno
 - ★ Reemplazar los dos grupos en un nuevo grupo
 - ★ Vuelva a calcular las puntuaciones de similitud entre grupos con respecto al nuevo grupo
 - ▶ Repita el paso anterior hasta que queden k grupos (k puede ser 1)




Casa abierta al tiempo

- Agrupamiento jerárquico (de abajo a arriba)
- Inicial



Casa abierta al tiempo


- Agrupamiento jerárquico (de abajo a arriba)
- Iteración 1



Casa abierta al tiempo


Aglomerativo

- Agrupamiento jerárquico (de abajo a arriba)
- Iteración 2




Casa abierta al tiempo

- Agrupamiento jerárquico (de abajo a arriba)
- Iteración 3




Casa abierta al tiempo

- Agrupamiento jerárquico (de abajo a arriba)
- Iteración 4



Casa abierta al tiempo


- Agrupamiento jerárquico (de abajo a arriba)
- Iteración 5



Casa abierta al tiempo

Aglomerativo

- Agrupamiento jerárquico (de abajo a arriba)
- k agrupamientos




Casa abierta al tiempo

- Divisivo (de arriba hacia abajo)
 - ▶ Comience en la parte superior con todos los patrones en un grupo
 - ▶ El grupo se divide utilizando un algoritmo de agrupamiento plano
 - ▶ Este procedimiento se aplica de forma recursiva hasta que cada patrón esté en su propio grupo único



Casa abierta al tiempo

- Divisivo (de arriba hacia abajo)



Casa abierta al tiempo

Data set: $X = \{\overline{x}_1, \overline{x}_2, \dots, \overline{x}_n\}$
Clusters: $C_1, C_2, \dots, C_k$
Centroides : $V = \{\overline{v}_1, \overline{v}_2, \dots, \overline{v}_k\}$
Matriz de partición : $\Gamma = \{\gamma_{ij}\}$
$$\gamma_{ij} = \begin{cases} 1 & \text{si } \overline{x}_j \in C_i \\ 0 & \text{en otro caso} \end{cases}$$

Minimiza función

$$E(\Gamma, V) = \sum_{i=1}^k \sum_{j=1}^n \gamma_{ij} \|\overline{x}_j - \overline{v}_i\|^2$$



Casa abierta al tiempo


- Algoritmo iterativo:

- ▶ Inicializar los centroides V con vectores elegidos aleatoriamente de X
- ▶ Asignar cada patrón al grupo más cercano
- ▶ Recalcular la matriz de partición
- ▶ Repetir los dos pasos anteriores hasta que haya convergencia (ya no cambien de grupo)





Casa abierta al tiempo

- Desventajas
 - ▶ Depende de la inicialización




Casa abierta al tiempo

- Desventajas
 - ▶ Depende de la inicialización



Casa abierta al tiempo


- Desventajas
 - ▶ Depende de la inicialización



Casa abierta al tiempo

K-medias K-means

- ¿Cómo decidir K ?
 - ▶ Método de encontrar el codo



UAMI abierta al tiempo

¹<https://www.researchgate.net/profile/S-elaheh-Ghiasian>

- Agrupamiento suave
- Minimiza función

$$E(U, V) = \sum_{i=1}^k \sum_{j=1}^n u_{ij}^m \|\bar{x}_j - \bar{v}_i\|^2$$

- $U = [u_{ij}]_{k \times n}$ matriz de partición difusa $U_{ij} \in [0, 1]$

$$\sum_{i=1}^k u_{ij} = 1 \forall j = 1, \dots, n$$

- $m \in [1, \infty]$ parámetro difuso usualmente 2.



Casa abierta al tiempo

- AIMA
- Basadas en diapositivas de Liang Shan
(<https://www.researchgate.net/profile/Liang-Shan-11>) y Min Zhang



Casa abierta al tiempo